

João Victor Sousa

Título do seu TCC

Ilhéus - Bahia

2025

João Victor Sousa

Título do seu TCC

Trabalho apresentado ao Curso de Y da Universidade X como requisito parcial para obtenção do título de Bacharel.

Universidade Estadual de Santa Cruz
Curso de Graduação em Ciência da Computação

Orientador: Otacílio José Pereira

Ilhéus - Bahia

2025

Resumo

Escreva aqui o resumo do seu trabalho. Inclua objetivos, metodologia, resultados e conclusões.

Palavras-chave: palavra1. palavra2. palavra3.

Sumário

Sumário	3	
1	INTRODUÇÃO	5
2	METODOLOGIA	6
2.1	Particionamento dos dados e classes	6
2.2	Métricas	7
2.3	Tipos de redes usadas	8
2.4	Pré-processamento e entrada para os modelos	9
2.5	Desafios e estratégias	9
2.6	Arquiteturas	10
3	RESULTADOS	13
4	CONCLUSÃO	14
	REFERÊNCIAS	15

Lista de Siglas

AUC	Area Under Curve
RNN	Redes Neurais Recorrentes
CNN	Redes Neurais Convolucionais
LSTM	Long Short-Term Memory
AAMI	Association for the Advancement of Medical Instrumentation
GRU	Gated Unit Recurrent
ECG	Eletrocardiograma
TP	Verdadeiro Positivo
FP	Falso Positivo
TN	Verdadeiro Negativo
FN	Falso Negativo

1 Introdução

Texto da introdução.

2 Metodologia

Primeiramente, foi necessário definir qual banco de dados seria utilizado para o treinamento e a validação. Optou-se pelo *MIT-BIH Arrhythmia Database* (MOODY; MARK, 2005), recomendado pela AAMI. O banco é composto por 58 registros de eletrocardiograma (ECG), cada um com 30 minutos de duração. Os 23 primeiros registros foram selecionados aleatoriamente a partir de um conjunto de 4000 gravações de 24 horas realizadas em pacientes ambulatoriais do Beth Israel Deaconess Medical Center. Os 25 registros restantes foram escolhidos de modo a incluir arritmias raras, mas clinicamente significativas.

Uma característica importante desse banco é a anotação de cada batimento cardíaco em torno do complexo R, realizada por três cardiologistas independentes.

2.1 Particionamento dos dados e classes

Os dados foram particionados seguindo a estratégia inter-paciente proposta por Chazel et al. (apud Silva et al. (2025)), na qual batimentos de um mesmo paciente não podem aparecer simultaneamente nos conjuntos de treinamento e validação. O objetivo é garantir a capacidade de generalização do modelo para diferentes pacientes. Além disso, conforme recomendado pela AAMI, registros de pacientes com marcapasso foram excluídos.

Os registros 101, 106, 108, 109, 112, 114, 115, 116, 118, 119, 122, 124, 201, 203, 205, 207, 208, 209, 215, 220, 223 e 230 foram utilizados para treinamento (conjunto DS1). Os demais (100, 103, 105, 111, 113, 117, 121, 123, 200, 202, 210, 212, 213, 214, 219, 221, 222, 228, 231, 232, 233 e 234) formaram o conjunto de teste (DS2).

De acordo com a AAMI (apud Silva et al. (2025)), são definidas cinco classes de arritmia: N, SVEB, VEB, F e Q, correspondentes a batimento normal, batimento supraventricular ectópico, batimento ventricular ectópico, fusão de batimento ventricular e normal e batimento não classificado, respectivamente. A Tabela 1 apresenta a distribuição dessas classes no conjunto de dados.

Tabela 1 – Particionamento inter-paciente proposto por Chazel et al.

Conjunto	N	SVEB	VEB	F	Q	Total
DS1	45 866	944	3 788	415	8	51 021
DS2	44 259	1 837	3 221	388	7	49 712
Total	90 125	2 781	7 009	803	15	100 733

Fonte: Adaptado de Silva et al. (2025).

O conjunto DS1 foi então subdividido em treinamento e validação por meio de validação cruzada, inicialmente com duas partições (dois *folds*) e, posteriormente, com cinco partições (cinco *folds*) nos modelos finais.

Considerando o desbalanceamento dos dados e visando maior simplicidade, adotou-se a classificação binária, na qual a classe positiva corresponde a arritmia e a classe negativa a batimentos normais.

2.2 Métricas

As métricas utilizadas para avaliar o desempenho dos modelos foram: sensibilidade, precisão, acurácia, *F1-score* e AUC (*Area Under the Curve*).

A sensibilidade representa a capacidade do modelo em identificar corretamente as classes positivas, isto é, os batimentos arrítmicos. Sua equação é dada por:

$$\text{Sensibilidade} = \frac{TP}{TP + FN} \quad (2.1)$$

em que TP são os verdadeiros positivos e FN os falsos negativos.

A precisão, por sua vez, indica a proporção de batimentos classificados como arrítmicos que realmente pertencem a essa classe:

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (2.2)$$

onde FP representa os falsos positivos. Precisão e sensibilidade estão relacionadas por um *trade-off*. No contexto médico, prioriza-se elevada sensibilidade, ainda que à custa de menor precisão, uma vez que falsos negativos são mais prejudiciais que falsos positivos.

O *F1-score* é a média harmônica entre precisão e sensibilidade, buscando um equilíbrio entre ambas:

$$F1\text{-score} = \frac{2 \cdot \text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} \quad (2.3)$$

A acurácia corresponde ao acerto global do modelo, considerando tanto as classes positivas quanto as negativas:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.4)$$

A AUC mede a capacidade do modelo em separar as classes positivas das negativas, variando entre 0 e 1. Valores próximos de 1 indicam separação perfeita, enquanto 0,5 corresponde a um modelo com desempenho equivalente ao acaso.

Essa métrica é calculada a partir da área sob a curva ROC, ilustrada na Figura 1.




Figura 1 – Exemplo de curva ROC: comparação entre modelo aleatório e modelo com bom desempenho.

A matriz de confusão, por fim, fornece uma representação tabular dos acertos e erros do modelo, como exemplificado na Tabela 2.

Tabela 2 – Exemplo de matriz de confusão binária

Classe Verdadeira	Classe Predita	
	Positiva	Negativa
Positiva	TP	FN
Negativa	FP	TN

Fonte: Elaborado pelo autor.

Essas métricas em conjunto permitem avaliar não apenas a proporção global de acertos, mas também a capacidade do modelo em detectar corretamente arritmias, aspecto essencial em aplicações médicas.

2.3 Tipos de redes usadas

Inicialmente, foram escolhidas redes neurais recorrentes (RNNs) e seus subtipos, como LSTM e GRU. Segundo James et al. (2023), esse tipo de rede apresenta grande potencial para lidar com dados sequenciais, como no processamento de linguagem natural,

previsão de preços e outros tipos de séries temporais. Como o componente temporal é relevante para o diagnóstico das arritmias, optou-se por esse tipo de modelo.

Além das RNNs, foram utilizadas redes neurais convolucionais (CNNs), conhecidas por sua habilidade em reconhecer padrões em diferentes domínios James et al. (2023). Em particular, CNNs unidimensionais (1D-CNNs) têm se mostrado eficazes na análise de sinais fisiológicos, sendo amplamente aplicadas à classificação de ECG (NAROTAMO et al., 2024).

A motivação para essa combinação está na complementaridade entre os modelos: enquanto as RNNs são eficazes na captura de dependências temporais, as CNNs se destacam na identificação de características morfológicas do sinal.

2.4 Pré-processamento e entrada para os modelos

Os sinais de ECG foram segmentados em batimentos individuais utilizando a biblioteca NeuroKit2 (MAKOWSKI et al., 2021).

O objetivo do trabalho é a classificação de batimentos cardíacos em duas classes: arrítmicos e normais. Para isso, os modelos recebem uma sequência de batimentos e realizam a classificação do último batimento da sequência. Cada sequência é composta exclusivamente por batimentos de um único paciente.

Tanto as CNNs quanto as RNNs recebem como entrada uma matriz tridimensional com a seguinte estrutura: (tamanho do batch, tamanho da sequência, número de features).

Para otimização do processo de treinamento, foram utilizados os mecanismos de *early stopping* e *reduce on plateau*, responsáveis por limitar o número de épocas e ajustar dinamicamente a taxa de aprendizagem, respectivamente.

2.5 Desafios e estratégias

O banco MIT-BIH apresenta desafios consideráveis para a classificação de arritmias, com 48 pacientes, cada um com 30 minutos de gravação em condições reais. Três problemas principais precisam ser superados: escassez de dados individuais, presença de ruído e desbalanceamento das classes, conforme mostrado na Tabela 1.

A estratégia de classificação binária ajuda parcialmente a lidar com o desbalanceamento, pois o modelo, em vez de identificar cinco classes diferentes, precisa classificar apenas duas.

Outra dificuldade está na própria arritmia. Certos tipos apresentam sinais muito parecidos ou praticamente idênticos aos normais, diferenciando-se apenas pelo ritmo. Outros possuem morfologias bem distintas no ECG. Inicialmente, foram utilizadas RNNs,

mas os modelos apresentaram dificuldades de generalização, evidenciadas pela diferença entre desempenho em treino e teste.

Para contornar essa limitação, foram incorporadas CNNs, permitindo que as RNNs se concentrassem na captura de padrões temporais, enquanto as CNNs extraem as características morfológicas do ECG.

Além disso, a estratégia de divisão inter-paciente dificulta a tarefa, pois o modelo recebe no conjunto de validação sinais de pacientes diferentes, simulando um cenário clínico mais realista. Para atingir bons resultados nesse conjunto, o modelo precisa aprender padrões gerais, independentes das variações individuais de cada paciente.

É importante frisar que a adoção desta estratégia torna os resultados mais aplicáveis a cenários clínicos gerais, e que a não utilização dela em outros trabalhos não invalida seus resultados; apenas limita a sua aplicabilidade nesse cenário.

O uso de engenharia de *features* também pode auxiliar os modelos. Embora redes profundas sejam capazes de aprender automaticamente representações a partir dos dados brutos, a inclusão de *features* pode ser especialmente útil em cenários com dados limitados. Os detalhes das *features* utilizadas neste trabalho são apresentados na Seção 2.6.

2.6 Arquiteturas

Foram testadas dois tipos de arquiteturas, uma é o uso de RNNs puras e a outra é uma arquitetura híbrida com CNNs.

A primeira arquitetura de pura é composta por três camadas de GRUs com 256 unidades ocultas. Essa arquitetura foi utilizada em Narotamo et al. (2024), obtendo o melhor desempenho. A diferença é que nesse trabalho, além da rede receber o sinal do ECG, ela também recebeu os intervalos RRs pré e pós:




Figura 2 – Arquitetura híbrida CNN+GRU.

A segunda rede é uma híbrida de CNN com GRU:

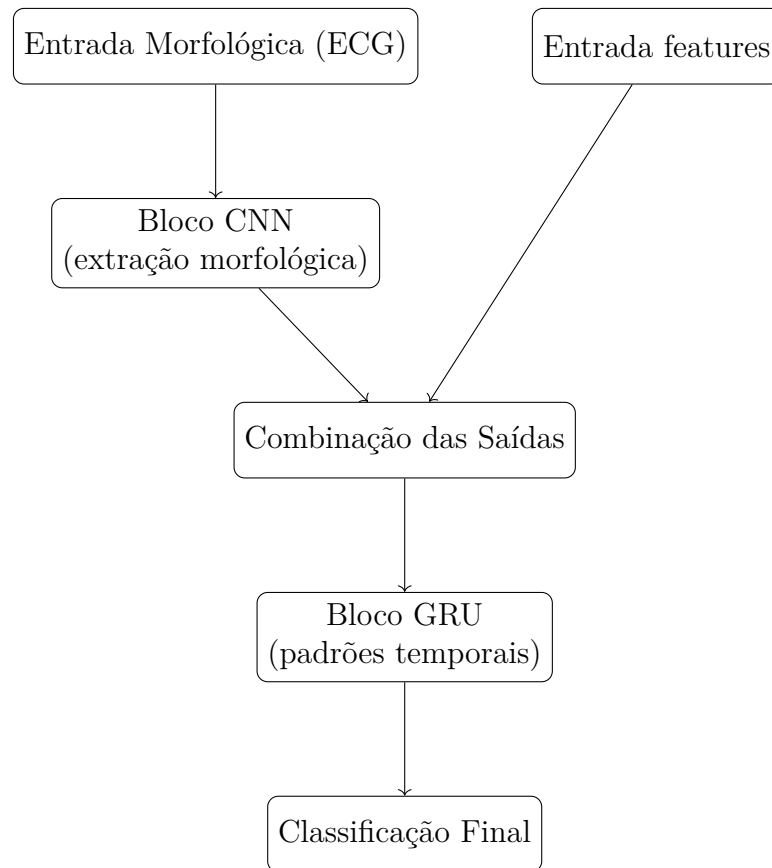


Figura 3 – Arquitetura híbrida CNN+GRU.

O bloco de CNN precisou ser aplicado em cada batimento dentro da sequência. Trata-se de duas camadas de CNN com 32 e 64 filtros respectivamente e cada uma seguida por uma camada de *batch normalization* e *global max pooling* para evitar sobre ajuste e reduzir as *features* respectivamente.

Enquanto que a rede da figura 2 recebeu o ECG concatenado com as *features*, a rede híbrida as recebeu separadas, sendo conectadas após o processamento das CNNs.

3 Resultados

Texto dos resultados.

4 Conclusão

Texto da conclusão.

Referências

JAMES, G. et al. *An Introduction to Statistical Learning: with applications in Python*. Cham: Springer, 2023. Disponível em: <<https://www.statlearning.com/>>. Acesso em: 28 ago. 2025.

MAKOWSKI, D. et al. NeuroKit2: A python toolbox for neurophysiological signal processing. *Behavior Research Methods*, Springer Science and Business Media LLC, v. 53, n. 4, p. 1689–1696, feb 2021. Disponível em: <<https://doi.org/10.3758%2Fs13428-020-01516-y>>.

MOODY, G. B.; MARK, R. G. *MIT-BIH Arrhythmia Database*. 2005. Disponível em: <<https://www.physionet.org/physiobank/database/mitdb/>>. Acesso em: 28 set. 2025.

NAROTAMO, H. et al. Deep learning for ecg classification: A comparative study of 1d and 2d representations and multimodal fusion approaches. *Biomedical Signal Processing and Control*, Elsevier, 2024.

SILVA, G. A. L. et al. *A Systematic Review of ECG Arrhythmia Classification: Adherence to Standards, Fair Evaluation, and Embedded Feasibility*. 2025. ArXiv:2503.07276v1. Acesso em: 28 set. 2025.